소프트웨어 설계 명세서

Software Design Document (SDD)

문서 코드: SDD

프로젝트명	BusanMate — 부산 맞춤 여행코스 안내 서비스
팀명	[팀명 입력]
팀원	김지호 / 2243577 / PM·LLM 에이전트 김성민 / 2242764 / 프론트, 연동 장우혁 / 2254772 / 데이터 엔지니어 이주호 / 2143325 / AI, 이미지
버전	v1.0
작성일	2026-10-13
담당교수	임한신

문서 관리

버전	날짜	작성자	변경 내용
0.1	2026-10-06	김지호	초안 작성 (SRS v0.1 기준)
0.2	2026-10-13	김지호	요구사항-설계 추적성 강화 (SRS 최종본 기준)
1.0	2026-10-13	김지호	최종본

1. 설계 개요 (Design Overview)

1.1 목적 및 범위

본 문서는 SRS 에 정의된 BusanMate 의 요구사항(FR-001~014, NFR-001~011, AI-REQ-01~06)을 어떻게 구현할지 설계한다. 범위는 서비스 전체(프론트엔드, API, 에이전트, 도구, 데이터 파이프라인)이며, 숙박·교통 예약, 숙소 추천, 부산 외 지역, 3 박 이상 일정, 모바일 앱, 다국어는 설계 대상이 아니다. 본 문서의 수치와 임계값은 초안 값이며 프로토타입 평가 후 조정한다.

추적성 원칙: 주요 설계 요소에는 관련 SRS 요구사항 ID(FR/NFR/AI-REQ)를 명시

1.2 관련 문서

- 요구사항 명세서(SRS) v1.0 — BusanMate
- 프로젝트 계획서 v1.0 — BusanMate
- 공공데이터포털·TourAPI, 기상청, 카카오 맵·모빌리티 공식 문서 (이용 조건과 호출 한도는 API 키 신청 시 확인)

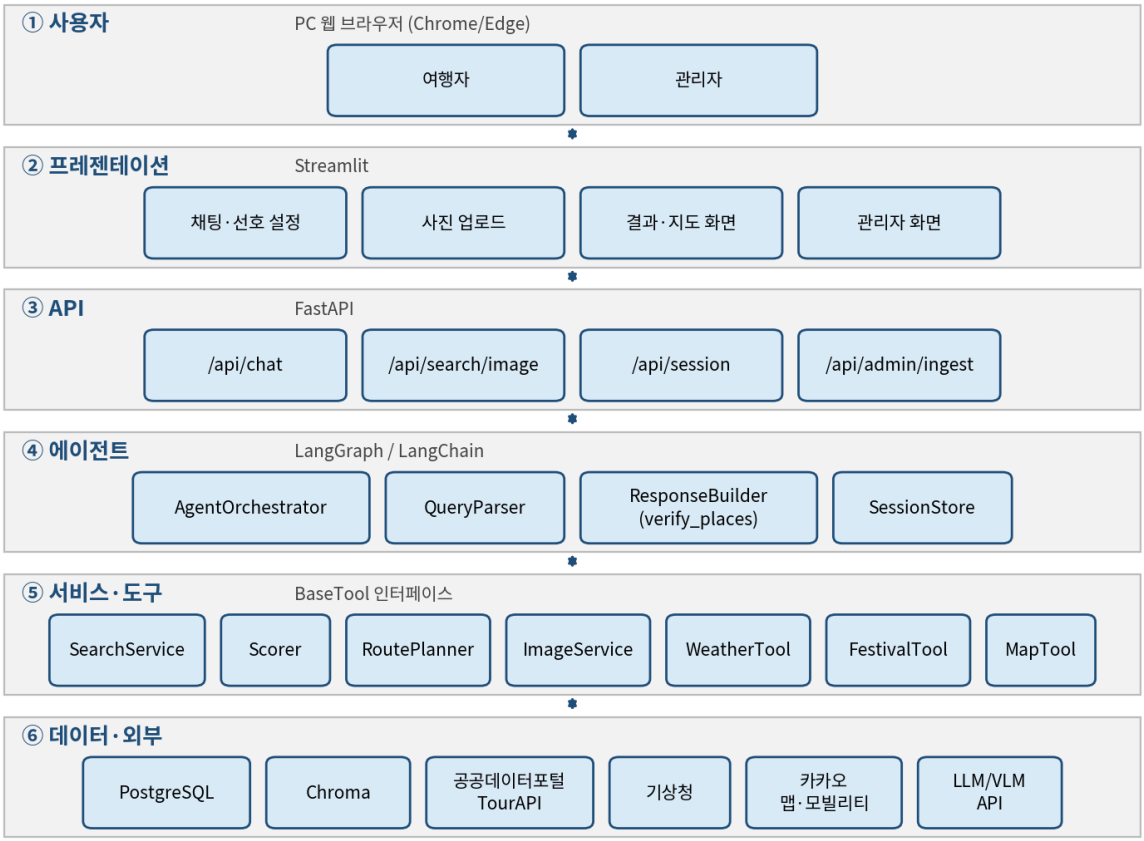
1.3 설계 목표 및 품질 속성

품질 속성	목표	설계 대응	관련 NFR
근거 신뢰성	추천 장소 100%가 DB 에 존재하고 출처 표시	LLM 은 장소를 id 로만 인용하고 verify_places 가 DB 와 대조, 이름·좌표·출처는 DB 에서 채움	NFR-004, AI-REQ-01
성능	텍스트 검색 5 초, 1 일 코스 15 초(2 박 3 일 30 초), 사진 검색 10 초 이내(중앙값)	하이브리드 검색으로 후보 30 개로 축소, 점수화·경로 계산은 코드로 처리, 응답 캐시	NFR-001, NFR-002
가용성·오류 복구	외부 API 장애에도 서비스 지속	DB·캐시 데이터로 응답하고 최신 정보가 아님을 안내, 이동 시간은 비저장·실패 시 직선거리 추정	NFR-003, AI-REQ-02
유지보수성	도구 추가 시 에이전트 코드 무수정	외부 연동을 공통 BaseTool 인터페이스로 구현, LLM/VLM 클라이언트 분리	NFR-009
보안·개인정보	키 노출 0 건, 사진 비저장	API 키는 .env 주입, 업로드 사진은 메모리에서만 처리, 로그에 개인정보 미기록	NFR-005, NFR-006, AI-REQ-03
저작권·출처	이용 조건 확인 데이터만 사용	DataPipeline 이 이용 조건(license)을 함께 적재하고 화면에 출처 표기	NFR-007, FR-003
사용성·비용	처음 쓰는 사용자가 3 분 내 코스 수령, API 비용 예산 내	단일 채팅 화면과 선호 설정, 호출 로그 집계와 응답 캐시	NFR-008, NFR-010

2. 시스템 아키텍처 (System Architecture)

2.1 전체 아키텍처

시스템은 사용자, 프레젠테이션, API, 에이전트, 서비스·도구, 데이터·외부의 6 계층으로 구성한다. 상위 계층은 바로 아래 계층만 호출한다. 공공 데이터는 DataPipeline 이 배치로 수집해 자체 DB 에 적재하고, 날씨·이동시간처럼 자주 바뀌는 정보만 질의 시점에 외부 API 에서 조회한다.



[그림 1] 시스템 아키텍처 (6 계층 구조)

표 1. 계층별 구성요소와 책임

계층	구성요소	책임	관련 요구사항
프레젠테이션	Streamlit 앱	채팅 입력, 사진 업로드, 선호 설정, 코스·지도·출처 표시, 관리자 화면. 상태는 session_id 만 보유	FR-005, FR-007, NFR-008
API	FastAPI	요청 검증, 세션 식별, 관리자 토큰 검사, 요청 한도, 오류 응답 표준화	FR-013, NFR-005
에이전트	AgentOrchestrator, QueryParser, ResponseBuilder, SessionStore	LangGraph 로 질의 흐름과 도구 호출 제어, 조건 추출, 설명 생성과 verify_places 장소 검증, 세션 보관(TTL 2 시간)	FR-001, FR-011, FR-012, AI-REQ-04, AI-REQ-05
서비스·도구	SearchService, Scorer, RoutePlanner, ImageService, WeatherTool, FestivalTool, MapTool	하이브리드 검색, 점수화·장소 선택·방문 순서 최적화, 사진 인식, 예보·행사·이동시간 조회 (도구는 BaseTool 구현)	FR-002, FR-004, FR-006~010, FR-014

계층	구성요소	책임	관련 요구사항
데이터·외부	PostgreSQL, Chroma, DataPipeline, 외부 API	장소 속성 / 텍스트·이미지 벡터 저장, 공공 API 수집·정제·적재, 공공데이터포털·TourAPI·기상청·카카오·LLM/VLM 연동	FR-003, FR-013, NFR-003, NFR-007

2.2 아키텍처 스타일 및 선택 이유

결정 ID	선택	이유	대안/Trade-off	관련 요구사항
ADR-001	계층형 + 클라이언트-서버, 모놀리식 API	책임 분리가 쉽고 4 인 팀·짧은 기간에 배포와 디버깅이 단순함	서비스 분리 대비 확장성이 낮고 계층 호출 오버헤드가 생김	NFR-009
ADR-002	RAG (속성 필터 + 벡터 하이브리드 검색)와 [[place_id]] 검증	부산 공공 데이터를 근거로 답하고 환각을 막음	임베딩 구축 비용과 검색 품질 튜닝 필요	AI-REQ-01, NFR-004, FR-002
ADR-003	LLM 에이전트(LangGraph)는 해석·도구 선택·설명, 점수화·경로 최적화는 코드	결과가 결정적이어서 시험이 쉽고 LLM 비용·오류 영향이 작음	LLM 의 도구 선택 오류 가능, 단계 수 제한 필요	AI-REQ-04, FR-006
ADR-004	공공 데이터는 배치 적재, 날씨·이동시간만 실시간 조회	호출 한도와 응답시간 확보, 이동시간은 약관상 캐싱 금지 가능성 반영	데이터 최신성이 배치 주기에 의존	NFR-001, NFR-003
ADR-005	PostgreSQL(속성) + Chroma(벡터) 이원 저장	관계형 질의와 벡터 검색을 각각 최적 도구로 처리	두 저장소의 동기화 관리 필요	FR-002, FR-008
ADR-006	외부 연동 도구의 공통 BaseTool 인터페이스	도구를 추가해도 에이전트 코드를 고치지 않음	추상화 계층에 따른 초기 구현 비용	NFR-009
ADR-007	세션은 서버 메모리(TTL 2 시간), 업로드 사진은 비저장	개인정보 최소화와 구현 단순화	서버 재시작 시 세션 소실	NFR-006, AI-REQ-03, FR-012
ADR-008	LLM·VLM 응답 캐시 (이동 시간 제외)	응답시간 단축과 API 비용 절감	캐시 일관성·만료 관리 필요	NFR-001, NFR-010

3. 컴포넌트 설계 (Component Design)

ID	컴포넌트	책임	입력	출력	의존성	관련 요구사항
COMP-01	Streamlit UI	채팅·사진 업로드·선호 설정, 코스·지도·출처 표시, 관리자 화면	사용자 입력, 파일	HTTP 요청, 화면	COMP-02	FR-005, FR-007, NFR-008
COMP-02	API 서버 (FastAPI)	요청 검증, 세션 식별, 관리자 토큰 검사, 요청 한도, 오류 응답 표준화	HTTP 요청	JSON 응답	COMP-03, COMP-08, COMP-12	FR-013, NFR-005
COMP-03	AgentOrchestrator	LangGraph 로 질의 흐름 제어, 도구 선택·호출, 턴당 도구 호출 6 회 제한	message, session_id	코스·응답	COMP-04~11	FR-011, FR-012, AI-REQ-04
COMP-04	QueryParser	조건 추출(지역·날짜·기간·동행·테마·시간·이동수단), 되묻기 판단	질의, 선호	Conditions	COMP-11	FR-001, AI-REQ-05
COMP-05	SearchService	속성 필터 + 벡터 하이브리드 검색, 후보 N=30, 조건 완화	Conditions	후보 장소 목록	PostgreSQL, Chroma	FR-002, AI-REQ-01
COMP-06	Scorer · RoutePlanner	점수화, 장소 수 결정, 다양성 보정, 일별 분배, 방문 순서 최적화	후보, Conditions, 날씨	일별 코스	COMP-07	FR-004~006, FR-014

ID	컴포넌트	책임	입력	출력	의존성	관련 요구사항
COMP-07	도구 어댑터 (Weather·Festival·Map)	예보·행사·이동시간 조회, BaseTool 구현, 실패 시 폴백	날짜·지역·코스	ToolResult	기상청, DB, 카카오	FR-004, FR-007, FR-010, NFR-003, NFR-009
COMP-08	ImageService	사진 검증·임베딩, 유사 장소 탐색, VLM 장면 설명 폴백	이미지 바이트	유사 장소 5 곳	Chroma, COMP-11	FR-008, FR-009, AI-REQ-06
COMP-09	ResponseBuilder	설명 생성, verify_places 장소 검증, 출처 첨부, 응답 조립	코스, 도구 결과	최종 응답	COMP-11, PostgreSQL	FR-003, FR-011, NFR-004
COMP-10	SessionStore	선호·직전 코스·대화 이력 보관 (TTL 2 시간)	session_id	세션 상태	서버 메모리	FR-005, FR-012
COMP-11	LLM/VLM Client	모델 호출 추상화, 응답 캐시, 호출 로그 기록	Prompt, 이미지	모델 응답	LLM/VLM API	AI-REQ-02, NFR-009, NFR-010
COMP-12	DataPipeline	공공 API 수집·정제·중복 제거·임베딩·적재, 수집 로그	관리자 실행	적재 결과·로그	공공 API, PostgreSQL, Chroma	FR-013, NFR-007

3.1 핵심 처리 로직

아래 수치(가중치, 임계값, 체류 시간 등)는 초안 값이며 config.yaml 로 분리해 평가 결과를 보고 조정한다.

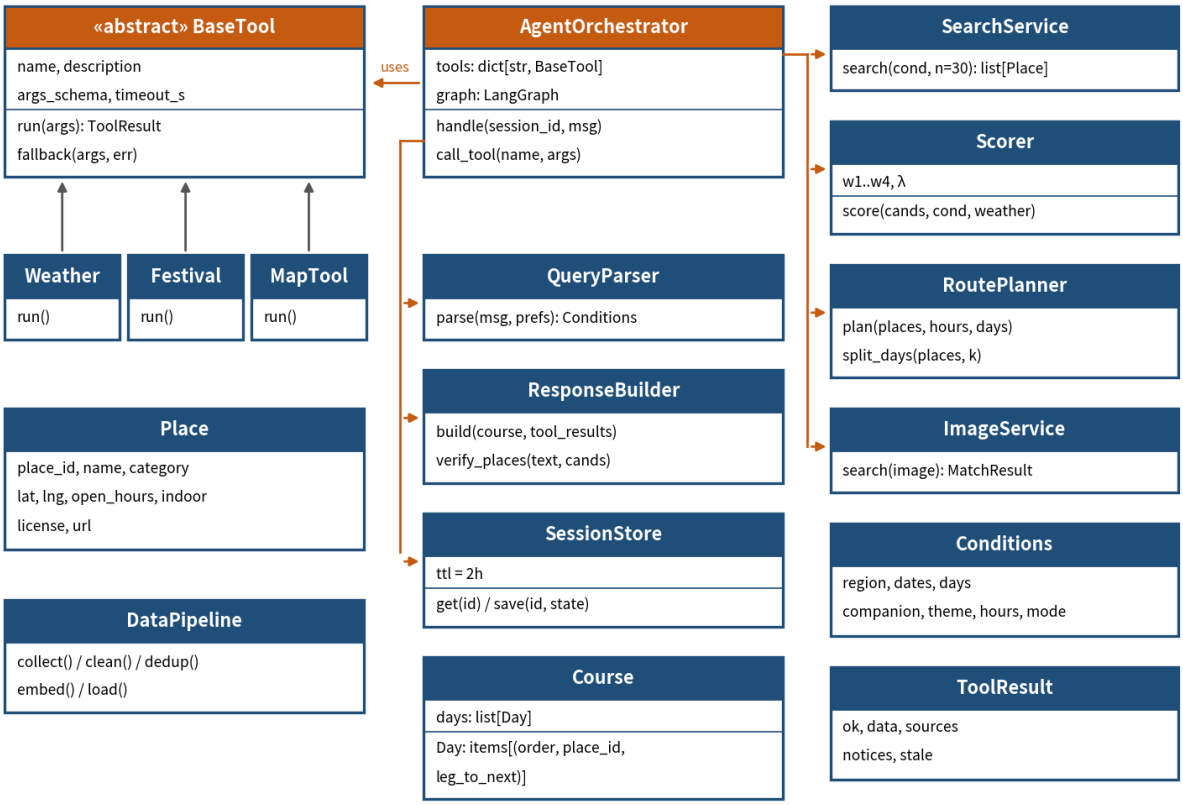
- 조건 추출 (COMP-04, FR-001): LLM 의 structured output 으로 지역·날짜·기간(1~3 일)·동행·테마·시간·이동수단을 JSON 으로 만든다. 지역·날짜가 없으면 되묻고, 나머지는 선호 설정과 기본값(하루 9 시간)을 쓴다. 기간이 3 일을 넘으면 3 일로 줄이고 안내한다.
- 하이브리드 검색 (COMP-05, FR-002): 구·분류·실내 여부·운영 시간 속성 필터를 적용한 뒤 Chroma 유사도 검색으로 상위 30 곳을 가져온다. 후보가 2 곳 미만이면 운영시간 → 실내 여부 → 구 순서로 조건을 풀어 다시 검색하고 풀었음을 안내한다.
- 점수화 (COMP-06, FR-004~006): S(p) = w1·sim + w2·pref + w3·weather − w4·dist (초기 가중치 0.4 / 0.3 / 0.2 / 0.1). weather 항은 강수확률 60% 이상이면 실내 1, 실외 0 을 주고 예보가 없으면 중립 0.5 를 준다.
- 코스 구성 (COMP-06, FR-006): 장소 수 K = clamp(floor(가용시간 / (평균 체류 + 평균 이동)), 2, 6). 점수 순으로 고르되 같은 분류가 이미 선택됐으면 λ=0.1 씩 감점하고, 방문 순서는 K ≤ 6 이므로 모든 순열(최대 720 가지) 중 이동거리가 최소인 것을 고른다. 같은 분류 3 곳 연속은 제외하며, 시간이 초과되면 최저 점수 장소를 빼고 운영시간 밖이면 다음 후보로 교체한다.
- 다일 일정 (COMP-06, FR-014): 상위 N 일 × K 곳을 후보 풀로 잡고 위·경도 k-means(k=일수)로 지리적 그룹을 나눈다. 강수확률 60% 이상인 날에는 실내 비율이 높은 그룹을 배정하고, 일정 전체에서 장소 중복이 없도록 교체 후보를 관리한다.
- 이동 시간 (COMP-07, FR-007): 자동차는 카카오 모빌리티 길찾기 API(자동차 경로만 제공)로 구간별 조회한다. 도보·대중교통과 조회 실패 시에는 직선거리 × 구간 보정계수(같은 구 1.3, 인접 구 1.5, 바다·다리 구간 1.8)로 추정해 "예상"으로 표시한다. 약관상 캐싱 금지 가능성이 있어 이동 시간은 저장하지 않는다.
- 사진 탐색 (COMP-08, FR-008·009): 형식·용량(JPG/PNG, 10MB) 검증 후 메모리에서 CLIP 임베딩을 만들어 place_image 를 검색한다. 최고 유사도가 τ=0.80 이상이면 장소를 인식하고, 미만이거나 부산 밖 사진이면 VLM 장면 설명을 임베딩해 place_text 에서 비슷한 분위기의 장소 5 곳을 찾는다. 처리 후 이미지는 폐기한다.

3.2 BaseTool 인터페이스

외부 연동 도구는 모두 공통 BaseTool 인터페이스를 구현한다. BaseTool 은 name, description, args_schema, timeout_s 속성과 run(args) → ToolResult, fallback(args, err) 메서드를 가진다. ToolResult 는 ok, data, sources(제공처·원본 링크), notices(사용자 안내), stale(대체 데이터 여부)를 담는다. AgentOrchestrator 는 도구 레지스트리에서 이름으로 도구를 찾아 호출하므로 도구를 추가해도 에이전트 코드는 바뀌지 않는다 (NFR-009).

4. UML 설계

4.1 Class Diagram



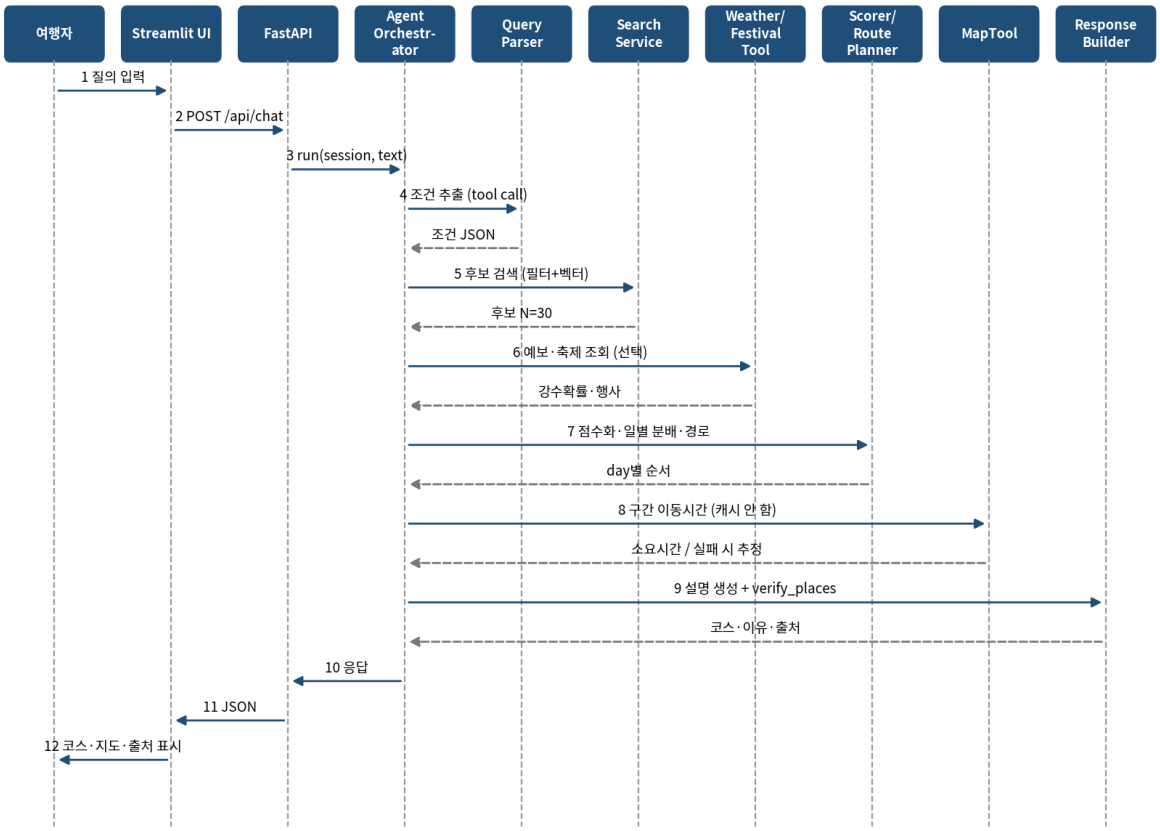
회색 화살표: 상속, 주황 화살표: 호출(의존). AgentOrchestrator가 도구 레지스트리와 서비스를 호출한다.

[그림 2] 클래스 다이어그램 (핵심 서비스·도구 클래스)

관련 요구사항: FR-001~FR-014, NFR-009

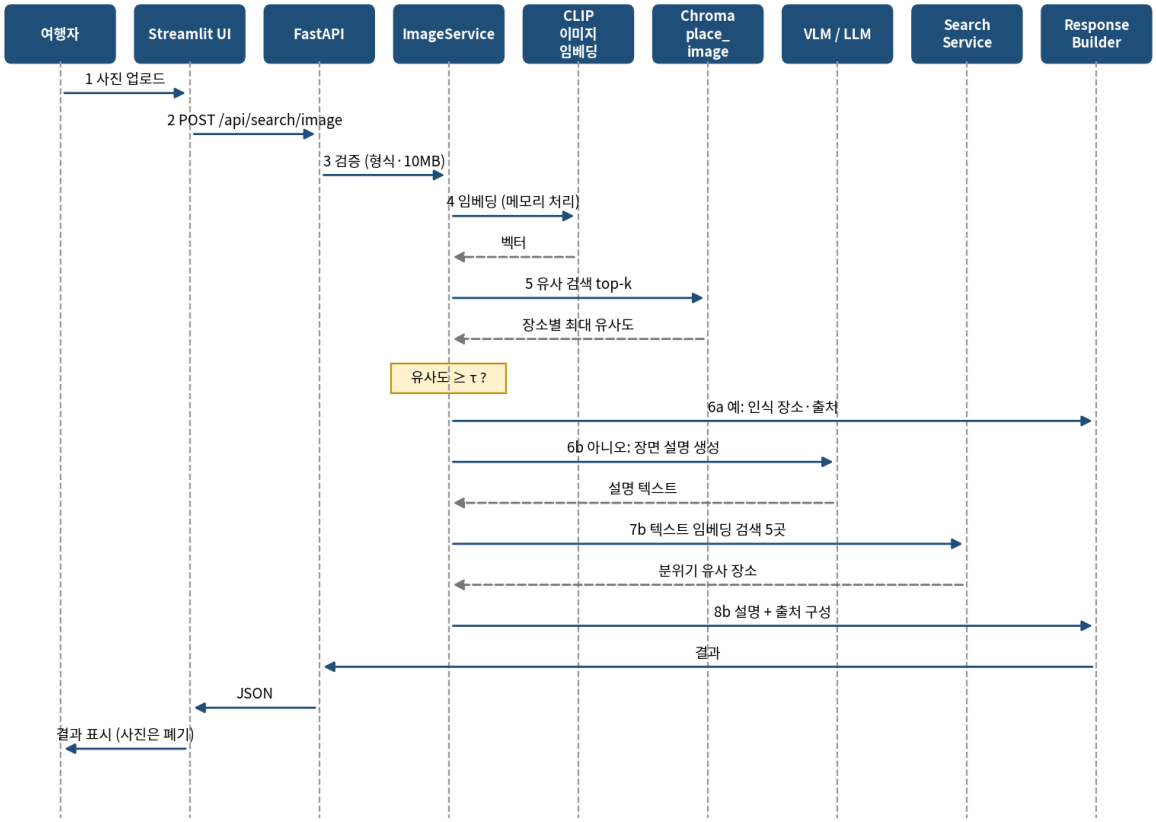
관련 Use Case: UC-001~UC-007

4.2 Sequence Diagram



[그림 3] SD-01. UC-002 맞춤 여행코스 추천 시퀀스

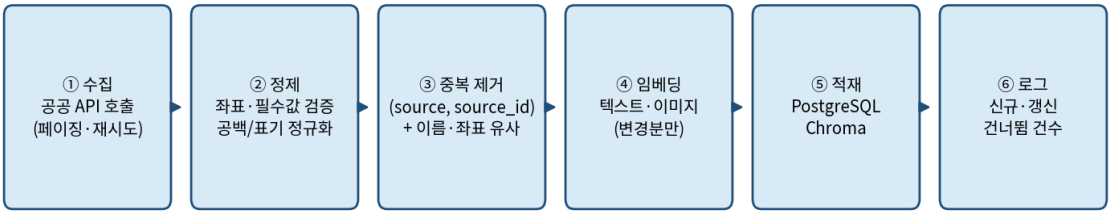
관련 Use Case: UC-002 관련 요구사항: FR-001~FR-007, FR-010, FR-011, FR-014, AI-REQ-01, AI-REQ-04



[그림 4] SD-02. UC-003 사진으로 장소 탐색 시퀀스

관련 Use Case: UC-003 관련 요구사항: FR-008, FR-009, AI-REQ-03, AI-REQ-06

4.3 기타 UML (선택)

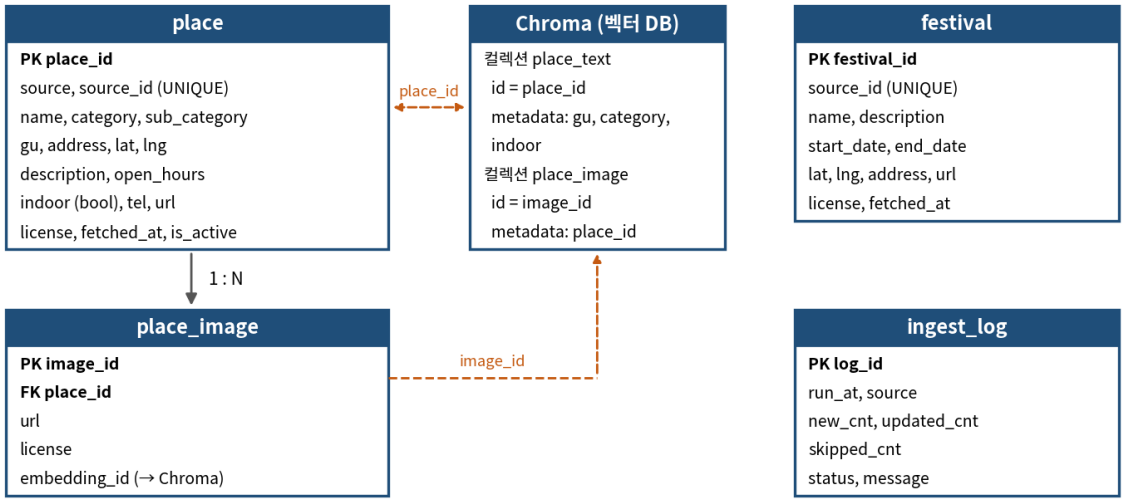


[그림 5] 데이터 수집 파이프라인 (Activity)

관련 요구사항/Use Case: FR-013, NFR-007 / UC-007

5. 데이터베이스 및 데이터 설계

5.1 ER Diagram / Data Model



[그림 6] 데이터 구조 (PostgreSQL / Chroma / 세션)

관련 요구사항: FR-002, FR-003, FR-008, FR-010, FR-013, NFR-006, NFR-007

5.2 테이블/컬렉션 정의

테이블/컬렉션	필드	타입	PK/FK	Null	설명	관련 요구사항
place	place_id	BIGSERIAL	PK	N	내부 식별자 (LLM 이 인용하는 id)	FR-002
place	source, source_id	VARCHAR	UNIQUE	N	수집 출처와 원본 id	FR-013
place	name	VARCHAR	-	N	장소명	FR-001
place	category, sub_category	VARCHAR	-	N / Y	분류, 세부 분류	FR-002, FR-006
place	gu, address	VARCHAR	-	N	구, 주소	FR-002
place	lat, lng	DOUBLE	-	N	좌표 (없으면 적재 제외)	FR-007
place	description	TEXT	-	Y	설명 (텍스트 임베딩 원문)	FR-002, FR-011
place	open_hours	TEXT/JSONB	-	Y	운영시간 (파싱 실패 시 원문)	FR-006
place	indoor	BOOLEAN	-	Y	실내 여부 (불명이면 NULL)	FR-004
place	tel, url	VARCHAR	-	Y	연락처, 원본 링크 (출처 표시)	FR-003

테이블/컬렉션	필드	타입	PK/FK	Null	설명	관련 요구사항
place	license	VARCHAR	-	N	이용 조건 (공공누리 유형 등)	FR-003, NFR-007
place	fetched_at, is_active	TIMESTAMP, BOOL	-	N	수집 시각, 활성 여부	FR-013
place_image	image_id	BIGSERIAL	PK	N	이미지 식별자	FR-008
place_image	place_id	BIGINT	FK	N	place 참조	FR-008
place_image	url, license	VARCHAR	-	N	이미지 위치, 이용 조건 (확인된 것만 적재)	NFR-007
place_image	embedding_id	VARCHAR	-	Y	Chroma 벡터 id	FR-008, FR-009
festival	festival_id	BIGSERIAL	PK	N	행사 식별자	FR-010
festival	source_id	VARCHAR	UNIQUE	N	원본 id	FR-013
festival	name, description	VARCHAR, TEXT	-	N / Y	행사명, 설명	FR-010
festival	start_date, end_date	DATE	-	N	기간 (겹치는 행사 조회)	FR-010
festival	lat, lng, address, url	DOUBLE, VARCHAR	-	Y	위치, 원본 링크	FR-003, FR-010
festival	license, fetched_at	VARCHAR, TIMESTAMP	-	N	이용 조건, 수집 시각	NFR-007
ingest_log	log_id	BIGSERIAL	PK	N	로그 식별자	FR-013
ingest_log	run_at, source	TIMESTAMP, VARCHAR	-	N	실행 시각, 소스	FR-013
ingest_log	new_cnt, updated_cnt, skipped_cnt	INT	-	N	신규·갱신·건너뜀 건수	FR-013
ingest_log	status, message	VARCHAR, TEXT	-	N / Y	결과 상태, 메시지	FR-013

Chroma 컬렉션과 세션은 아래와 같이 구성한다.

- place_text: id=place_id, 문서=이름+설명, 메타데이터=gu·category·indoor, 코사인 유사도.
- place_image: id=image_id, 메타데이터=place_id. 사진 검색 후 place_id 별 최대 유사도로 집계한다.
- 세션: 서버 메모리 dict(TTL 2 시간). preferences{테마, 이동수단, 동행}, last_course, 최근 대화 N 턴을 두며 DB 에는 저장하지 않는다. 업로드 사진도 저장하지 않는다 (NFR-006).

6. API 설계

API ID	Method	Endpoint	목적	Request	Response	관련 요구사항
API-001	POST	/api/chat	자연어 질의 → 코스·설명·출처	{session_id, message}	{answer, conditions, course, sources, notices}	FR-001~007, FR-010~012, FR-014
API-002	POST	/api/search/image	사진 → 인식 결과 또는 유사 장소 5 곳	multipart (session_id, file)	{mode, matches, sources, notices}	FR-008, FR-009
API-003	GET	/api/session/{id}/preferences	선호 조회	-	{theme, mode, companion}	FR-005
API-004	PUT	/api/session/{id}/preferences	선호 설정	{theme, mode, companion}	{ok}	FR-005
API-005	GET	/api/session/{id}/course	직전 코스 조회	-	{course}	FR-007, FR-012
API-006	POST	/api/admin/ingest	수집 배치 실행 (X-Admin-Token)	{sources?}	{run_id}	FR-013
API-007	GET	/api/admin/ingest/{run_id}	수집 상태·결과 조회	-	{status, new, updated, skipped}	FR-013
API-008	GET	/api/health	상태 확인	-	{status}	NFR-003

chat 응답의 course 는 일자별 items(order, place_id, name, lat, lng, reason, leg_to_next{minutes, meters, estimated})로 구성하며, answer 속 장소 마커는 서버가 DB 의 장소명으로 치환한 뒤 반환한다. 관리자 API 는 X-Admin-Token 헤더를 환경변수의 토큰과 상수 시간 비교로 검사한다.

공통 오류 응답

HTTP / code	상황	시스템 동작	사용자 안내
400 INVALID_INPUT	필수 조건(지역·날짜) 누락, 잘못된 파라미터	처리 중단	부족한 조건을 되묻는다
401 UNAUTHORIZED	관리자 토큰 없음·불일치	요청 거부	관리자 권한이 필요합니다
413/415 FILE_*	10MB 초과, JPG/PNG 아님	요청 거부	허용 형식·용량 안내
429 RATE_LIMITED	세션당 분당 20 회 초과 (초안)	요청 거부	잠시 후 다시 시도
502/504 UPSTREAM_*	LLM/VLM·외부 API 실패	폴백 응답	최신 정보 아님 표시
500 INTERNAL	처리되지 않은 오류	일반 오류 응답	상세는 로그에만 기록

7. AI / LLM / VLM 설계

7.1 AI 파이프라인



[그림 7] AI 파이프라인

관련 요구사항: AI-REQ-01~AI-REQ-06, FR-001, FR-008, FR-011, NFR-004

에이전트 도구 목록

도구	역할	주요 인자	구현 모듈
search_places	조건에 맞는 후보 검색	Conditions	SearchService
get_weather	방문일 강수확률 조회	date, region	WeatherTool
get_festivals	방문 기간 행사 조회	start, end	FestivalTool
build_course	점수화·일별 분배·순서 결정	candidates, Conditions, days	Scorer, RoutePlanner
get_route_times	구간 이동 시간 조회	course, mode	MapTool

도구	역할	주요 인자	구현 모듈
edit_course	교체·추가·삭제 부분 반영	op, target_index, spec	Orchestrator, Scorer
search_by_image	사진 검색 (별도 엔드포인트)	image_ref	ImageService

- LLM 은 질의 의도(검색·코스·수정)에 따라 필요한 도구를 선택하고, 점수화·경로·시간 계산은 도구 안의 코드가 수행한다 (AI-REQ-04).
- 한 턴의 도구 호출은 최대 6 회로 제한하고, build_course 는 search_places 결과가 있을 때만 실행한다. 순서가 어긋난 호출은 오류로 돌려 LLM 이 다시 선택하게 한다.

7.2 모델 및 인터페이스

AI 요소	모델/서비스	역할	입력/출력	교체 가능성/추상화	관련 요구사항
LLM	Google Gemini (AI Studio 무료 등급)	조건 추출, 도구 선택, 설명 생성	Text+Context → JSON/Text	LLMClient 인터페이스	AI-REQ-01, AI-REQ-04, FR-001, FR-011
VLM	Google Gemini (멀티모달)	사진 장면 설명 (유사도 미달 시)	Image+Text → Text	VLMClient 인터페이스	AI-REQ-06, FR-009
텍스트 임베딩	미정 (한국어 지원 모델)	장소 설명·질의 벡터화	Text → Vector	EmbeddingProvider	FR-002, AI-REQ-01
이미지 임베딩	CLIP 계열	사진·장소 이미지 벡터화	Image → Vector	EmbeddingProvider	FR-008, AI-REQ-06

7.3 Prompt 설계

- System Prompt 목적: 도구 결과에 있는 장소만 언급하고, 장소는 [[place_id]] 마커로만 가리키게 하며, 모르면 모른다고 답하고 필수 조건이 없으면 되묻게 한다. 숙박·예약·결제는 다루지 않고 한국어로 답한다. 프롬프트는 agent/prompts/에 버전과 함께 관리한다.
- 검색 대상 데이터/Chunk 전략: 장소 1 건을 1 개 문서(이름 + 설명)로 임베딩하며 별도 분할은 하지 않는다. 사진은 장소별 이미지 1 장당 1 벡터로 저장한다. LLM 에는 후보를 id, 이름, 분류, 한 줄 요약 형태로만 보여 준다.
- Top-k 또는 Retrieval 기준: 속성 필터 통과 후보 중 의미 유사도 상위 N=30 을 가져와 점수화로 K 곳(2~6)을 고른다. 사진은 상위 10 개 이미지를 place_id 별 최대 유사도로 집계해 5 곳을 만들고, 유사도 τ=0.80 이상이면 인식으로 처리한다.
- 출처 표시 방식: 응답에 포함된 모든 장소에 제공처, 원본 링크, 이용 조건(license)을 붙이며 화면 하단과 README 에도 표기한다. 출처가 없는 장소는 응답에서 제외한다.
- Hallucination 완화 방법: LLM 은 이번 턴의 후보만 보고, 응답은 마커로만 장소를 가리킨다. verify_places 가 모든 마커 id 가 DB·후보 집합에 있는지 확인해 없으면 해당 문장을 제거하고 통과한 마커는 DB 의 이름으로 치환한다. 문장 속 가짜 장소명은 규칙만으로 모두 걸러낼 수 없으므로 평가 질의 50 개로 DB 와 자동 대조해 0 건을 측정한다.

관련 요구사항: AI-REQ-01, AI-REQ-04, FR-003, FR-011, NFR-004

7.4 AI 실패/예외 처리

상황	처리 전략	사용자 메시지/로그	관련 요구사항
LLM API Timeout·오류	키워드·규칙 기반 간이 추출로 검색 결과만 반환, 같은 질의의 응답 캐시가 있으면 사용	"AI 설명을 만들지 못해 검색 결과만 보여 드립니다" / 오류·지연 로그	AI-REQ-02
VLM 실패	CLIP 유사도 결과만 반환	"사진 설명 없이 유사한 장소만 보여 드립니다"	AI-REQ-02

상황	처리 전략	사용자 메시지/로그	관련 요구사항
기상청 예보 실패	날씨 반영 없이 진행 (weather 항 중립)	"날씨 정보를 가져오지 못해 반영하지 않았습니다"	AI-REQ-02, NFR-003
이동 시간 API 실패	직선거리 기반 추정치로 대체 (저장 안 함)	"이동 시간은 직선거리 기반 예상치입니다"	NFR-003
근거 부족 (후보 2 곳 미만)	조건을 단계적으로 완화해 재검색, 그래도 없으면 결과 없음 안내	"조건을 조금 넓혀 볼까요?" 완화 내용 표시	AI-REQ-01
장소 검증 실패	검증 실패 문장 제거, 후보 외 장소 미노출	검증 실패 로그 (장소 id)	AI-REQ-01, NFR-004
부적절 입력 (형식·길이)	검증 후 차단, 파일 형식·용량 위반은 413/415	허용 형식·용량 안내	AI-REQ-03

8. 예외 처리 및 로깅

오류 ID	오류 상황	시스템 동작	로그/모니터링	관련 요구사항
ERR-001	잘못된 입력 (필수 조건 누락)	400 응답, 되묻기	입력 오류 로그	FR-001, FR-002
ERR-002	관리자 토큰 불일치	401 응답	인증 실패 로그 (토큰 미기록)	FR-013, NFR-005
ERR-003	파일 형식·용량 위반	413/415 응답	입력 오류 로그 (크기·형식만)	FR-008, NFR-006
ERR-004	요청 한도 초과	429 응답	한도 초과 로그	NFR-001
ERR-005	외부 AI(LLM/VLM) 장애	폴백 응답 + 안내 (502/504)	오류·응답시간·폴백 사용 로그	AI-REQ-02, NFR-003
ERR-006	기상청·카카오 API 실패	날씨 미반영 / 직선거리 추정	도구별 오류 로그	FR-004, FR-007, NFR-003
ERR-007	장소 검증 실패 (환각 의심)	해당 문장 제거	검증 실패 로그 (장소 id)	FR-011, NFR-004
ERR-008	수집 소스 실패	해당 소스 건너뜀, 최대 3 회 재시도	ingest_log, 관리자 화면	FR-013
ERR-009	DB·벡터 저장소 장애	500 응답 (일반 메시지)	오류 로그, 상세는 서버 로그에만	NFR-003

로깅 정책

- 구조화(JSON) 로그에 request_id, 세션 해시, 단계별 지연, 도구 호출 목록, 오류 코드, 폴백 사용 여부를 남긴다.
- LLM·VLM 호출 로그에 모델, 입출력 토큰, 추정 비용, 지연을 남기고 일 단위로 집계해 팀 예산 대비를 확인한다 (NFR-010).
- 질의 원문, 업로드 사진, API 키·토큰은 로그에 남기지 않는다 (NFR-005, NFR-006).

9. 보안 및 개인정보 설계

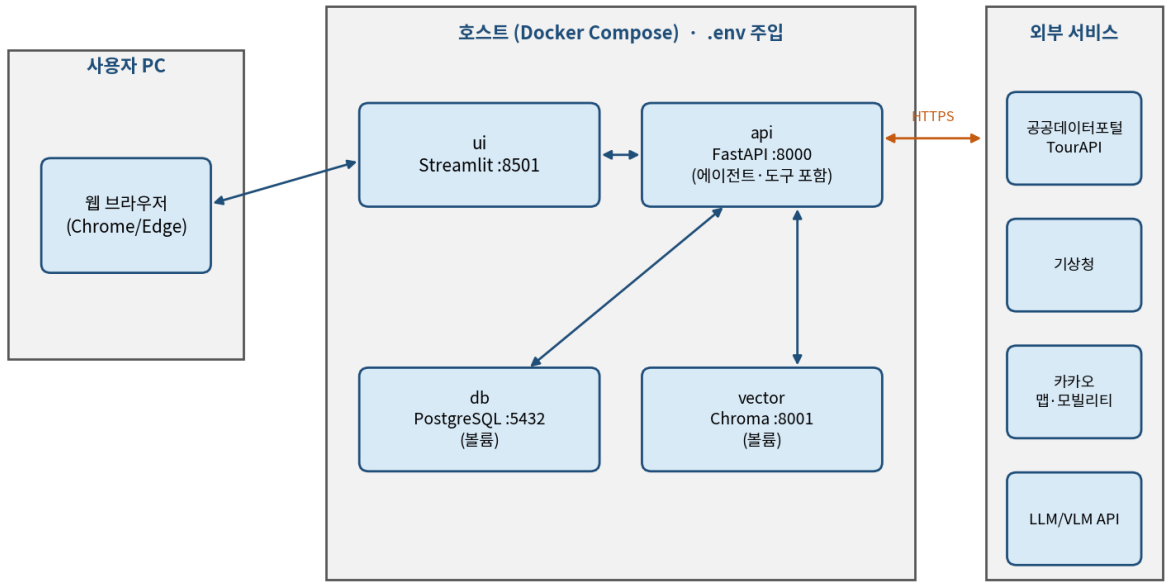
- 인증/권한: 일반 사용자는 로그인 없이 session_id 단위로 사용한다. 관리자 API 는 X-Admin-Token 헤더를 환경변수의 토큰과 상수 시간 비교로 검사한다.
- API Key/Secret 관리: 모든 비밀값은 .env 환경변수로 주입하고 저장소에는 .env.example 만 올린다. pre-commit gitleaks 와 GitHub secret 스캔을 켠다.
- 개인정보 저장 최소화: 업로드 사진은 메모리에서만 처리하고 응답 후 폐기한다. 세션은 서버 메모리에 TTL 2 시간으로 두며 회원정보는 수집하지 않는다.
- 입력/출력 검증: 파일 형식(확장자·매직바이트)과 10MB 제한, 질의 길이 제한, Pydantic 스키마 검증, 세션당 분당 20 회 요청 한도. 출력은 verify_places 검증을 거친 장소만 반환한다.
- 로그에 민감정보를 남기지 않음: 로그에는 요청 id, 세션 해시, 도구별 소요시간, 오류 코드만 남기고 질의·사진 원문은 남기지 않는다.

관련 요구사항 매핑

보안/개인정보 설계 요소	관련 요구사항
인증/권한	FR-013, NFR-005
API Key/Secret 관리	NFR-005
개인정보 저장 최소화	NFR-006, AI-REQ-03
입력/출력 검증	NFR-004, NFR-006, AI-REQ-03
민감정보 로그 방지	NFR-006, AI-REQ-03

10. 배포 및 운영 설계

10.1 Deployment Diagram



[그림 8] 배포 구성 (Docker Compose)

관련 요구사항: NFR-005, NFR-006, NFR-011

서비스	이미지/기술	포트(초안)	비고
ui	Python 3.11 + Streamlit	8501	api 만 호출
api	Python 3.11 + FastAPI(uvicorn)	8000	에이전트·도구·서비스 포함 (모놀리식)
db	PostgreSQL	5432	볼륨으로 데이터 영속화
vector	Chroma (퍼시스턴트 디렉터리)	8001	볼륨으로 인덱스 영속화

에이전트와 도구를 api 프로세스 안에 두는 모놀리식 구조로 시작하며, 팀 규모와 기간을 고려해 서비스 분리는 하지 않는다. 저장소는 ui/, api/, agent/, tools/, services/, pipeline/, db/, eval/, tests/, docs/ 디렉터리로 나눈다.

10.2 CI/CD

- Repository/Branch 전략: GitHub 저장소의 main 은 보호 브랜치로 두고 직접 푸시하지 않는다. 작업은 feature/<기능> 브랜치에서 하고 PR 로 병합한다.

- Pull Request/Review 규칙: 리뷰어 1 명 이상의 승인과 CI 통과 후 병합한다. PR 본문에 관련 FR/이슈 번호를 적는다.
- 자동 Build/Test: GitHub Actions 에서 PR 마다 ruff(lint), pytest, gitleaks(secret 스캔)를 실행한다.
- 배포 환경: Docker Compose (발표 시연용 로컬 실행 또는 서버 배포는 미결, 아래 10.4 참고).

관련 요구사항: NFR-005, NFR-009, NFR-011

10.3 성능 예산

단계	예산	비고	관련 NFR
조건 추출 (LLM)	2 초	구조화 출력, 짧은 프롬프트	NFR-001
검색 (SQL + Chroma)	1 초	N=30	NFR-001
날씨·축제 조회	1 초	병렬 호출, 날씨 1 시간 캐시	NFR-001
점수화·경로 계산	1 초 미만	하루 최대 720 가지 전수 탐색	NFR-001
이동 시간 조회	3 초	구간 병렬 호출, 시간 초과 시 추정	NFR-001, NFR-003
설명 생성·검증 (LLM)	6 초	장소별 reason 일괄 생성	NFR-001
합계 (1 일 코스)	약 14 초	목표 15 초. 2 박 3 일은 날짜별 병렬화로 30 초	NFR-001
사진 검색	10 초 이내	임베딩 + 검색 + (폴백 시) VLM	NFR-002

가중치(w1~w4), 다양성 보정 λ, 구간 보정계수표, 강수확률 임계값, 후보 수 N, 기본 체류 시간, 이동 속도, 사진 임계값 τ, 세션 TTL, 요청 한도, 도구 timeout 은 config.yaml 로 관리하고 비밀값만 .env 에 둔다.

10.4 설계 미결 사항

- 텍스트 임베딩, CLIP 모델 선정: 개발 초기 PoC 에서 정확도·지연·비용을 비교해 확정한다. LLM/VLM 은 Gemini(무료 등급)로 정했다.
- 공공 API 실제 응답 필드와 DB 컬럼 매핑, 운영시간 형식, indoor 추정 규칙: API 키 승인 후 샘플로 확인한다.
- 가중치, 강수확률 임계값, τ, 체류 시간·이동 속도, 구간 보정계수: 평가셋과 실측(대표 구간 약 20 쌍)으로 조정한다.
- 카카오 길찾기 API 호출 가능 여부와 약관(캐싱 금지 범위), 도보 경로 API 필요 여부, 카카오맵 활성화·도메인 등록을 확인한다.
- 세션 보관 방식(현재 서버 메모리, 필요 시 Redis 등)과 배포 방식(로컬 시연 vs 서버)을 결정한다.

11. 디자인 패턴 및 주요 설계 원칙

패턴/원칙	적용 위치	적용 이유	관련 클래스/컴포넌트	관련 요구사항
Adapter / Strategy	LLM/VLM Client	모델 제공자 교체 용이	LLMClient, VLMClient	NFR-009, AI-REQ-02
Registry + Interface	BaseTool 도구 레지스트리	도구 추가 시 에이전트 코드 무수정	BaseTool, ToolResult	NFR-009, AI-REQ-04
Template Method	BaseTool.run / fallback	도구별 실패 처리 규약 통일	Weather·Festival·MapTool	NFR-003
Pipeline	DataPipeline	수집·정제·적재 단계 분리와 재실행(멱등)	DataPipeline	FR-013
Layered Architecture	전체 6 계층	책임 분리, 계층 간 단방향 호출	COMP-01~12	NFR-009
Graceful Degradation	외부 API 호출부	장애 시 DB·추정치로 응답	도구 어댑터	NFR-003, AI-REQ-02
Externalized Config	config.yaml, .env	수치 조정·비밀값 분리	설정 모듈	NFR-005, NFR-009

12. 요구사항-설계 추적표

요구사항 ID	Use Case	아키텍처/컴포넌트	Class/DB	API	Sequence	Test Case	상태/비고
FR-001	UC-001, UC-002	COMP-03, COMP-04	Conditions	API-001	SD-01	TC-001	Draft
FR-002	UC-001, UC-002	COMP-05	place / Chroma	API-001	SD-01	TC-002	Draft
FR-003	UC-001~003	COMP-09	place.url, license	API-001, API-002	SD-01, SD-02	TC-003	Draft
FR-004	UC-002	COMP-06, COMP-07	Scorer	API-001	SD-01	TC-004	Draft
FR-005	UC-002, UC-006	COMP-10, COMP-06	SessionStore	API-003, API-004	-	TC-005	Draft
FR-006	UC-002, UC-005	COMP-06	Scorer, RoutePlanner	API-001	SD-01	TC-006	Draft
FR-007	UC-002, UC-004, UC-005	COMP-07, COMP-01	MapTool	API-001, API-005	SD-01	TC-007	Draft
FR-008	UC-003	COMP-08	ImageService / place_image	API-002	SD-02	TC-008	Draft
FR-009	UC-003	COMP-08, COMP-05	ImageService	API-002	SD-02	TC-009	Draft
FR-010	UC-002	COMP-07	festival	API-001	SD-01	TC-010	Draft
FR-011	UC-002	COMP-03, COMP-09	verify_places	API-001	SD-01	TC-011	Draft
FR-012	UC-005	COMP-03, COMP-10	SessionStore	API-001, API-005	-	TC-012	Draft
FR-013	UC-007	COMP-12, COMP-02	ingest_log	API-006, API-007	-	TC-013	Draft
FR-014	UC-002	COMP-03, COMP-06	RoutePlanner	API-001	SD-01	TC-014	Draft
NFR-001	-	COMP-03, COMP-11	응답 캐시	API-001	SD-01	TC 추가 예정	Draft
NFR-002	-	COMP-08	ImageService	API-002	SD-02	TC 추가 예정	Draft
NFR-003	-	COMP-07, COMP-11	폴백 (§7.4)	API-001	SD-01	TC 추가 예정	Draft
NFR-004	-	COMP-09	verify_places	API-001	SD-01	TC 추가 예정	Draft
NFR-005	-	COMP-02	.env, gitleaks	API-006	-	TC 추가 예정	Draft
NFR-006	-	COMP-08, 로깅	메모리 처리, 로그 정책	API-002	SD-02	TC 추가 예정	Draft
NFR-007	-	COMP-12	place.license	-	-	TC 추가 예정	Draft
NFR-008	-	COMP-01	Streamlit UI	-	-	TC 추가 예정	Draft
NFR-009	-	COMP-07, COMP-11	BaseTool	-	-	TC 추가 예정	Draft
NFR-010	-	COMP-11	호출 로그, 응답 캐시	-	-	TC 추가 예정	Draft
NFR-011	-	COMP-01	Streamlit UI	-	-	TC 추가 예정	Draft
AI-REQ-01	UC-002	COMP-05, COMP-09	verify_places / Chroma	API-001	SD-01	TC-011	Draft
AI-REQ-02	UC-002	COMP-07, COMP-11	폴백 (§7.4)	API-001	SD-01	TC 추가 예정	Draft
AI-REQ-03	UC-003	COMP-08	메모리 처리	API-002	SD-02	TC 추가 예정	Draft
AI-REQ-04	UC-002	COMP-03	BaseTool	API-001	SD-01	TC 추가 예정	Draft
AI-REQ-05	UC-002	COMP-04	Conditions	API-001	SD-01	TC-001	Draft
AI-REQ-06	UC-003	COMP-08, COMP-11	ImageService	API-002	SD-02	TC-008, TC-009	Draft

※NFR 항목의 Test Case 는 SRS 추적표와 같이 추가 예정이다. 구현·테스트가 진행되면서 API/Class/Test Case 매핑을 보완한다.